

**ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIỀN TIẾN CLC & POHE**



BÁO CÁO PHÂN TÍCH DỮ LIỆU

Đề tài: Bank Marketing Dataset

Giảng viên: Ts. Trần Đức Minh

Lớp: AEP.TOKT1138.LS(225)CLC_06_TL_02

Thành viên:	<i>Vũ Hoàng Ngọc Minh</i>	<i>11246712</i>
	<i>Bùi Hoàng Giang</i>	<i>11244954</i>
	<i>Lê Khánh Ly</i>	<i>11247476</i>
	<i>Chu Tường Vi</i>	<i>11246731</i>
	<i>Thân Thị Loan</i>	<i>11244343</i>

Hà Nội, ngày 15 tháng 5 2026

MỤC LỤC

A.	HÀNH TRÌNH LÀM SẠCH DỮ LIỆU.....	3
I.	Giả thuyết nghiên cứu	3
II.	Từ Raw Data đến Clean Data · Project 2: Bank Marketing Dataset	4
	1. Tổng quan về dữ liệu thô	4
	2. Các thách thức và quyết định xử lý trong quá trình làm sạch.....	5
	3. Kết quả cuối cùng sau quá trình làm sạch	13
	4. Nhận xét sau làm sạch	13
B.	QUY TRÌNH THỰC THI (Từ Dữ liệu Sạch đến Insight).....	14
I.	Kiểm tra và Hợp nhất Dữ liệu (Data Integration)	14
	1. Tổng quan về quy trình Data Integration	14
	2. Kiểm tra tính nhất quán cấu trúc của dữ liệu.....	15
	3. Xác định mối quan hệ và khóa dữ liệu	17
	4. Tự động hóa hợp nhất dữ liệu	18
	5. Tổng kết – Kết quả kiểm tra và hợp nhất.....	19
II.	Phân tích khám phá dữ liệu (EDA)	20
	1. Kiểm định giả thuyết.....	20
	2. Phân tích tương quan	27
	3. Phân bố và ngoại lệ	29
III.	Đánh giá bằng biểu đồ (Visual Analysis)	33
	1. Biểu đồ cột (Bar Chart): So sánh hiệu suất giữa các danh mục	33
	2. Biểu đồ tán xạ (Scatter Plot): Mối quan hệ giữa hai biến định lượng.....	35
	3. Biểu đồ đường (Line Chart): Theo dõi xu hướng thời gian	36
C.	TỔNG KẾT VÀ ĐỀ XUẤT (CONCLUSION)	37
I.	Tổng hợp Insight.....	37
II.	Giá trị thực tiễn	38
III.	Hạn Chế và Hướng Phát Triển	39
	1. Hạn chế hiện tại.....	39
	2. Hướng phát triển.....	40

A. HÀNH TRÌNH LÀM SẠCH DỮ LIỆU

I. Giả thuyết nghiên cứu

Trước khi bắt đầu xử lý dữ liệu, nhóm xác định rõ câu hỏi nghiên cứu trung tâm mà toàn bộ dự án hướng đến:

“Liệu có thể dự đoán khách hàng nào sẽ đăng ký tiền gửi có kỳ hạn - dựa trên đặc điểm nhân khẩu học và hành vi trong chiến dịch gọi điện của ngân hàng?”

Đây không đơn thuần là bài toán phân loại kỹ thuật. Đúng từ góc nhìn nghiệp vụ, ngân hàng đang cần trả lời một câu hỏi thực tế hơn: *Nên ưu tiên gọi điện cho nhóm khách hàng nào để tối ưu chi phí chiến dịch và tăng tỷ lệ chuyển đổi?*

Từ câu hỏi trung tâm đó, nhóm đặt ra ba nhóm giả thuyết nhỏ để kiểm chứng trong suốt quá trình phân tích:

Giả thuyết 1: Nhân khẩu học ảnh hưởng đến quyết định đăng ký

Nhóm giả định rằng các đặc điểm cá nhân như độ tuổi, nghề nghiệp, trình độ học vấn và tình trạng tài chính hiện tại sẽ phân hóa rõ ràng khả năng đăng ký. Cụ thể, khách hàng đang có gánh nặng tài chính (vay nhà, vay tiêu dùng) được kỳ vọng sẽ ít sẵn sàng gửi tiết kiệm hơn, trong khi nhóm đã nghỉ hưu hoặc sinh viên, nhóm tuổi có ít áp lực chi tiêu hơn có thể có tỷ lệ đăng ký cao hơn mức trung bình.

Giả thuyết 2: Hành vi trong chiến dịch phản ánh mức độ quan tâm của khách hàng

Nhóm giả định rằng thời gian cuộc gọi (duration) là tín hiệu mạnh nhất: khách hàng nào dành nhiều thời gian lắng nghe tư vấn viên thì có khả năng cao hơn sẽ đăng ký. Ngược lại, số lần gọi quá nhiều (campaign cao) có thể gây hiệu ứng ngược, phản ánh sự từ chối nhiều lần hơn là thiện chí. Ngoài ra, những khách hàng đã từng phản hồi tích cực ở chiến dịch trước (poutcome = success) được kỳ vọng là nhóm có tỷ lệ tái đăng ký cao nhất.

Giả thuyết 3: Thời điểm liên hệ tạo ra sự khác biệt về hiệu quả chiến dịch

Nhóm giả định rằng tỷ lệ chuyển đổi không đồng đều theo tháng. Một số thời điểm trong năm ví dụ như cuối quý hoặc cuối năm, khách hàng có thể có tâm lý tích lũy rõ ràng hơn, dẫn đến tỷ lệ đăng ký cao hơn dù số lượng cuộc gọi không phải lớn nhất.

Kết luận: Những giả thuyết này đóng vai trò kim chỉ nam cho toàn bộ quy trình phía sau. Ở bước làm sạch dữ liệu, nhóm ưu tiên bảo toàn các biến liên quan trực tiếp đến ba nhóm trên thay vì xử lý một cách cơ học. Đến bước EDA, mỗi biểu đồ và kiểm định được thiết kế để xác nhận hoặc bác bỏ từng giả thuyết cụ thể - thay vì chỉ mô tả dữ liệu một cách thụ động.

II. Từ Raw Data đến Clean Data · Project 2: Bank Marketing Dataset

Phần này trình bày quá trình nhóm chuyển đổi dữ liệu ngân hàng ban đầu thành một tập dữ liệu sạch, có cấu trúc và sẵn sàng cho phân tích khám phá dữ liệu (EDA). Thay vì chỉ liệt kê các thao tác xử lý, nhóm tập trung mô tả vấn đề phát hiện được, quyết định xử lý và lý do đằng sau từng quyết định.

Thông điệp chính

Dữ liệu không có giá trị NaN/null không đồng nghĩa với việc dữ liệu đã sẵn sàng phân tích. Với bộ dữ liệu này, các vấn đề quan trọng nằm ở giá trị “unknown”, định dạng chữ chưa đồng nhất, biến pdays có mã hóa ngầm, kiểu dữ liệu sau xử lý và các outlier cần được đánh giá theo ngữ cảnh ngân hàng.

1. Tổng quan về dữ liệu thô

Khi mở file dữ liệu gốc về Bank Marketing Dataset được cung cấp trên Kaggle, nhóm sẽ phải làm việc với 11.162 dòng và 17 cột (age, job, marital, education, default, balance, housing, loan, contact, day, month, duration, campaign, pdays, previous, poutcome, deposit), mô tả thông tin khách hàng cùng kết quả của chiến dịch marketing qua điện thoại. Biến mục tiêu là deposit, thể hiện khách hàng có đăng ký tiền gửi kỳ hạn hay không.

Bảng 1. Bảng tổng quan ban đầu

Chỉ số kiểm tra ban đầu	Kết quả	Nhận xét
Kích thước dữ liệu gốc	11.162 dòng × 17 cột	Đủ lớn để thực hiện EDA và mô hình hóa
Missing NaN/null	0	Không thiếu về mặt kỹ thuật
Dòng trùng lặp	0	Không cần loại bỏ bản ghi trùng
Biến mục tiêu deposit	yes/no	Cần mã hóa thành 1/0
Tỷ lệ deposit	yes: 47,38% · no: 52,62%	Tương đối cân bằng, thuận lợi cho mô hình

Giá trị unknown	Có ở 4 cột	Cần xem xét riêng vì không phải NaN nhưng mang nghĩa chưa xác định
-----------------	------------	--

Ở lần kiểm tra đầu tiên, nhóm cho ra kết quả dữ liệu không có missing value dạng NaN/null và không có dòng trùng lặp. Tuy nhiên, sau khi đi sâu hơn vào nội dung từng biến bằng lệnh `df.describe()` và `df.describe(include="object")`, nhóm nhận thấy dữ liệu vẫn còn nhiều vấn đề cần xử lý trước khi phân tích.

Bảng 2. Thống kê mô tả các biến định lượng trong dữ liệu thô

	age	balance	day	duration	campaign	pdays	previous
count	11162.000000	11162.000000	11162.000000	11162.000000	11162.000000	11162.000000	11162.000000
mean	41.231948	1528.538524	15.658036	371.993818	2.508421	51.330407	0.832557
std	11.913369	3225.413326	8.420740	347.128386	2.722077	108.758282	2.292007
min	18.000000	-6847.000000	1.000000	2.000000	1.000000	-1.000000	0.000000
25%	32.000000	122.000000	8.000000	138.000000	1.000000	-1.000000	0.000000
50%	39.000000	550.000000	15.000000	255.000000	2.000000	-1.000000	0.000000
75%	49.000000	1708.000000	22.000000	496.000000	3.000000	20.750000	1.000000
max	95.000000	81204.000000	31.000000	3881.000000	63.000000	854.000000	58.000000

Từ bảng thống kê mô tả biến định lượng, nhóm nhận thấy một số biến có khoảng giá trị rất rộng, đặc biệt là balance, duration, campaign, pdays và previous. Ví dụ, balance có cả giá trị âm và giá trị rất lớn, cho thấy dữ liệu tài chính có khả năng bị lệch và cần kiểm tra outlier. Biến pdays có giá trị nhỏ nhất là -1, đây không phải là số ngày thực tế mà là mã đặc biệt cần xử lý riêng ở các bước sau.

Bảng 3. Thống kê mô tả các biến phân loại trong dữ liệu thô

	job	marital	education	default	housing	loan	contact	month	poutcome	deposit
count	11162	11162	11162	11162	11162	11162	11162	11162	11162	11162
unique	12	3	4	2	2	2	3	12	4	2
top	management	married	secondary	no	no	no	cellular	may	unknown	no
freq	2566	6351	5476	10994	5881	9702	8042	2824	8326	5873

Bảng thống kê mô tả các biến phân loại cho thấy một số biến có giá trị unknown, đặc biệt là poutcome với 8.326 quan sát, cho thấy cần xử lý unknown như một dạng dữ liệu thiếu đặc biệt. Ngoài ra, các biến nhị phân như default, housing, loan và deposit cần được mã hóa từ yes/no sang 1/0 để thuận tiện cho phân tích định lượng.

2. Các thách thức và quyết định xử lý trong quá trình làm sạch

2.1. Chuẩn hóa định dạng dữ liệu

Sau khi xác định các vấn đề liên quan đến missing đặc biệt và outlier, nhóm tiếp tục xử lý các vấn đề về định dạng dữ liệu. Đây là bước giúp pipeline xử lý dữ liệu bằng Python ổn định hơn.

Nhóm chuẩn hóa định dạng dữ liệu ở ba phần:

- Chuẩn hóa tên cột.
- Chuẩn hóa dữ liệu dạng chữ.
- Chuẩn hóa nhãn phân loại trong cột job.

2.1.1. Chuẩn hóa tên cột

Tên cột cần nhất quán để pipeline xử lý dữ liệu chạy ổn định. Nếu tên cột có khoảng trắng, chữ hoa/chữ thường không đồng nhất hoặc ký tự khó thao tác, quá trình viết code, truy vấn và xây dựng biểu đồ có thể dễ phát sinh lỗi.

Nhóm chuẩn hóa tên cột bằng cách loại bỏ khoảng trắng thừa, chuyển toàn bộ về chữ thường và thay khoảng trắng bằng dấu gạch dưới.

Kết quả sau khi chuẩn hóa tên cột sẽ được biểu diễn như sau:

“age”, “job”, “marital”, “education”, “default”, “balance”, “housing”, “loan”, “contact”, “day”, “month”, “duration”, “campaign”, “pdays”, “previous”, “poutcome”, “deposit”.

2.1.2. Chuẩn hóa dữ liệu dạng chữ

Các biến dạng chữ như job, marital, education, contact, month và poutcome cần được chuẩn hóa trước khi phân tích. Nếu cùng một giá trị nhưng khác chữ hoa, chữ thường hoặc có khoảng trắng thừa, Python có thể hiểu đó là các nhóm khác nhau.

Vì vậy, nhóm chuyển toàn bộ dữ liệu dạng chữ về chữ thường và loại bỏ khoảng trắng thừa. Đây là bước xử lý sai định dạng cơ bản giúp thống kê tần suất, vẽ biểu đồ và mã hóa biến phân loại không bị tách sai nhóm.

Bảng 4. Bảng kết quả 5 dòng đầu sau khi chuẩn hóa dữ liệu dạng chữ

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	deposit
0	59	admin.	married	secondary	no	2343	yes	no	unknown	5	may	1042	1	-1	0	unknown	yes
1	56	admin.	married	secondary	no	45	no	no	unknown	5	may	1467	1	-1	0	unknown	yes
2	41	technician	married	secondary	no	1270	yes	no	unknown	5	may	1389	1	-1	0	unknown	yes
3	55	services	married	secondary	no	2476	yes	no	unknown	5	may	579	1	-1	0	unknown	yes
4	54	admin.	married	tertiary	no	184	no	no	unknown	5	may	673	2	-1	0	unknown	yes

2.1.3. Chuẩn hóa nhãn category

Cột job có một số nhãn chứa dấu chấm hoặc dấu gạch ngang như admin., blue-collar và self-employed. Các định dạng này không sai về nội dung, nhưng gây bất tiện khi truy vấn dữ liệu hoặc mã hóa biến phân loại.

Nhóm chuẩn hóa các nhãn này để thống nhất quy ước đặt tên:

Giá trị ban đầu	Giá trị sau chuẩn hóa	Lý do
admin.	admin	Loại bỏ dấu chấm cuối nhãn
blue-collar	blue_collar	Dùng gạch dưới để thống nhất định dạng
self-employed	self_employed	Tránh ký tự đặc biệt khi xử lý tiếp

2.2. Dữ liệu không có NaN/null nhưng vẫn chưa thật sự sạch

Khi kiểm tra bằng `isna()`, dữ liệu không có missing value dạng NaN/null. Tuy nhiên nhóm nhận thấy một số thông tin chưa xác định được biểu diễn dưới dạng chuỗi “unknown”, đặc biệt ở các biến phân loại như job, education, contact và poutcome.

Vì vậy, nhóm không chỉ dừng lại ở kiểm tra missing value kỹ thuật, mà tiếp tục rà soát các giá trị đặc biệt trong từng cột dạng chữ. Cách tiếp cận này giúp phát hiện các vấn đề ẩn mà kiểm tra NaN thông thường không thể chỉ ra.

Bảng 5. Bảng missing NaN/Null ở từng cột

	missing_count	missing_percent
age	0	0.0
job	0	0.0
marital	0	0.0
education	0	0.0
default	0	0.0
balance	0	0.0
housing	0	0.0
loan	0	0.0
contact	0	0.0
day	0	0.0
month	0	0.0
duration	0	0.0
campaign	0	0.0
pdays	0	0.0
previous	0	0.0
poutcome	0	0.0
deposit	0	0.0

2.3. Nhóm vấn đề về missing value và giá trị ngoại lệ

Trong quá trình làm sạch, nhóm gặp hai nhóm vấn đề cần xử lý bằng các phương pháp thay thế giá trị:

- Giá trị thiếu dạng đặc biệt: unknown trong các biến phân loại.
- Giá trị ngoại lệ: outlier trong các biến định lượng.

Với hai nhóm vấn đề này, nhóm không dùng cùng một phương pháp xử lý. Với biến phân loại có unknown, nhóm dùng Mode Imputation trong các trường hợp phù hợp. Với biến định lượng có outlier, nhóm dùng Median Imputation cho những biến không mang ý nghĩa logic hoặc thời gian đặc biệt.

Việc đặt hai quyết định này gần nhau giúp thể hiện rõ tư duy xử lý dữ liệu của nhóm: chọn phương pháp thay thế dựa trên **loại dữ liệu** và **ý nghĩa của biến**, không xử lý máy móc tất cả các cột theo một cách giống nhau.

2.3.1. Xử lý unknown trong biến phân loại bằng Mode Imputation và giữ category riêng

Sau khi kiểm tra bằng lệnh `df_clean[col].eq("unknown").sum()`, nhóm phát hiện unknown xuất hiện ở 4 cột phân loại với tỷ lệ phần trăm khác nhau.

Bảng 6. Bảng thống kê giá trị unknown trong các biến phân loại

	column	unknown_count	unknown_percent
0	job	70	0.63
1	education	497	4.45
2	contact	2346	21.02
3	poutcome	8326	74.59

Sau khi kiểm tra được tỷ lệ phần trăm của giá trị unknow của từng biến, nhóm sẽ đưa ra cách xử lý giá trị "unknown" theo các phương pháp phù hợp.

Bảng 7. Bảng xử lý giá trị “unknown”

	column	method	mode_value	unknown_before	unknown_after
0	job	mode imputation	management	70	0
1	education	mode imputation	secondary	497	0
2	contact	keep as category	not applied	2346	2346
3	poutcome	keep as category	not applied	8326	8326

Với job và education, nhóm sử dụng Mode Imputation vì đây là các biến phân loại và tỷ lệ unknown không quá lớn. Mode là giá trị xuất hiện nhiều nhất trong cột, phù hợp để thay thế cho dữ liệu phân loại. Nhóm không dùng mean hoặc median cho hai biến này vì chúng không phải dữ liệu số.

Với contact và poutcome, nhóm giữ unknown như một category riêng. Lý do là unknown ở hai biến này có thể mang ý nghĩa nghiệp vụ. Ví dụ, contact = unknown có thể phản ánh chưa rõ kênh liên hệ, còn poutcome = unknown có thể phản ánh khách hàng chưa có kết quả rõ ràng từ chiến dịch trước. Nếu thay các giá trị này bằng mode, nhóm có thể làm mất đi tín hiệu quan trọng trong dữ liệu.

Nhóm không sử dụng prediction để dự đoán giá trị thiếu vì phương pháp này phức tạp hơn và chưa phù hợp với phạm vi xử lý dữ liệu cơ bản của bài.

2.3.2. Kiểm tra outlier và xử lý bằng Median Imputation ở biến định lượng

Bên cạnh unknown, nhóm cũng kiểm tra outlier ở các biến định lượng bằng phương pháp IQR. Phương pháp IQR được dùng vì không yêu cầu dữ liệu phân phối chuẩn, phù hợp với dữ liệu ngân hàng vốn thường có phân phối lệch. Với mỗi biến định lượng, nhóm tính Q1, Q3 và IQR, sau đó xác định ngưỡng dưới bằng $Q1 - 1.5 \times IQR$ và ngưỡng trên bằng $Q3 + 1.5 \times IQR$. Các giá trị nằm ngoài khoảng này được xem là outlier.

Bảng 8. Bảng kết quả kiểm tra outlier bằng IQR

	column	min	max	Q1	Q3	IQR	lower_bound	upper_bound	outlier_count	outlier_percent
6	pdays_clean	0	854	0.0	20.75	20.75	-31.125	51.875	2754	24.67
5	pdays	-1	854	-1.0	20.75	21.75	-33.625	53.375	2750	24.64
7	previous	0	58	0.0	1.00	1.00	-1.500	2.500	1258	11.27
1	balance	-6847	81204	122.0	1708.00	1586.00	-2257.000	4087.000	1055	9.45
3	duration	2	3881	138.0	496.00	358.00	-399.000	1033.000	636	5.70
4	campaign	1	63	1.0	3.00	2.00	-2.000	6.000	601	5.38
0	age	18	95	32.0	49.00	17.00	6.500	74.500	171	1.53
2	day	1	31	8.0	22.00	14.00	-13.000	43.000	0	0.00
8	month_num	1	12	5.0	8.00	3.00	0.500	12.500	0	0.00

Nhóm phát hiện outlier ở một số biến như age, balance, duration, campaign, pdays, pdays_clean và previous. Tuy nhiên, nhóm không xử lý tất cả outlier theo cùng một cách.

Với các biến age, balance, duration, campaign và previous, nhóm sử dụng Median Imputation để thay thế các giá trị ngoại lệ. Median được chọn vì ít bị ảnh hưởng bởi các giá trị quá lớn hoặc quá nhỏ hơn mean, phù hợp trong trường hợp dữ liệu có outlier.

Riêng các biến pdays, pdays_clean, day và month_num không được thay bằng median. Lý do là pdays và pdays_clean có ý nghĩa nghiệp vụ riêng liên quan đến lịch sử liên hệ khách hàng, còn day và month_num là biến thời gian. Nếu thay các biến này bằng median, ý nghĩa ban đầu của dữ liệu có thể bị sai lệch.

Bảng 9. Bảng kết quả xử lý outliers

	column	method	median_value	lower_bound	upper_bound	outlier_before	before_min	before_max	after_min	after_max
0	age	median imputation	39.0	6.5	74.5	171	18	95	18	74
1	balance	median imputation	550.0	-2257.0	4087.0	1055	-6847	81204	-2049	4087
2	duration	median imputation	255.0	-399.0	1033.0	636	2	3881	2	1033
3	campaign	median imputation	2.0	-2.0	6.0	601	1	63	1	6
4	previous	median imputation	0.0	-1.5	2.5	1258	0	58	0	2

2.4. Mã hóa và tạo biến phục vụ phân tích

Sau khi xử lý các vấn đề về missing đặc biệt, outlier và định dạng dữ liệu, nhóm tiếp tục biến đổi một số biến để dữ liệu phù hợp hơn cho phân tích định lượng và EDA.

2.4.1. Mã hóa các biến yes/no thành biến nhị phân

Một số biến như default, housing, loan và deposit ban đầu được lưu dưới dạng chữ yes/no. Dạng dữ liệu cần mã hóa để tính toán tương quan hoặc đưa vào mô hình machine learning.

Nhóm mã hóa các biến này thành dạng số, trong đó yes = 1 và no = 0. Với các biến chỉ có hai trạng thái, cách mã hóa này đơn giản, dễ hiểu và tránh tạo thêm cột dư thừa như khi sử dụng One-Hot Encoding.

2.4.2. Xử lý biến month

Cột month ban đầu được lưu dưới dạng chữ viết tắt như jan, feb, mar. Định dạng này phù hợp để hiển thị nhưng không thuận tiện khi cần sắp xếp theo thứ tự tháng hoặc phân tích xu hướng theo thời gian.

Nhóm tạo thêm biến month_num, chuyển các tháng từ jan đến dec thành các giá trị từ 1 đến 12. Cách xử lý này giúp nhóm vừa giữ lại cột month để hiển thị dễ hiểu, vừa có month_num để phân tích và trực quan hóa theo đúng thứ tự thời gian.

Mục đích	Biến sử dụng
Sắp xếp và phân tích xu hướng theo tháng	month_num
Hiển thị nhãn dễ đọc trên biểu đồ	month

Bảng 10. Minh họa kết quả tạo biến month_num từ biến month

	month	month_num
0	may	5
1	may	5
2	may	5
3	may	5
4	may	5

2.4.3. Xử lý biến pdays

Biến pdays biểu diễn số ngày kể từ lần liên hệ trước đó với khách hàng. Tuy nhiên, giá trị -1 không phải là số ngày thực tế, mà thể hiện khách hàng chưa từng được liên hệ trước đó. Có 8.324 bản ghi mang giá trị pdays = -1, tương đương 74,57% dữ liệu.

Nếu giữ nguyên -1, mô hình hoặc phân tích thống kê có thể hiểu nhầm đây là một giá trị số âm thật. Vì vậy, nhóm tách thông tin này thành hai biến mới: was_contacted_before và pdays_clean. Nhóm vẫn giữ lại pdays gốc để đảm bảo tính minh bạch và có thể đối chiếu khi cần.

Biến mới	Cách tạo	Ý nghĩa
was_contacted_before	0 nếu pdays = -1, ngược lại 1	Khách hàng đã từng được liên hệ trước đó hay chưa
pdays_clean	Thay pdays = -1 bằng 0	Phiên bản pdays không còn giá trị âm gây nhiễu

Bảng 11. Bảng kết quả kiểm tra pdays sau xử lý

	pdays	was_contacted_before	pdays_clean
0	-1	0	0
1	-1	0	0
2	-1	0	0
3	-1	0	0
4	-1	0	0
5	-1	0	0
6	-1	0	0
7	-1	0	0
8	-1	0	0
9	-1	0	0

2.5. Ép kiểu dữ liệu và kiểm tra chất lượng sau làm sạch

Sau các bước mã hóa và tạo biến mới, nhóm kiểm tra lại kiểu dữ liệu của toàn bộ bảng. Các biến số như age, balance, duration, campaign, previous, deposit, month_num, was_contacted_before và pdays_clean được ép về kiểu số nguyên.

Bước này giúp đảm bảo dữ liệu đầu ra có kiểu phù hợp trước khi chuyển sang EDA, trực quan hóa và mô hình hóa. Nếu kiểu dữ liệu không nhất quán, một số phép tính thống kê hoặc thuật toán machine learning có thể bị lỗi.

Bảng 12. Bảng kết quả sau khi ép dữ liệu

	0
age	int64
job	object
marital	object
education	object
default	int64
balance	int64
housing	int64
loan	int64
contact	object
day	int64
month	object
duration	int64
campaign	int64
pdays	int64
previous	int64
poutcome	object
deposit	int64
month_num	int64
was_contacted_before	int64
pdays_clean	int64

Sau khi hoàn tất các bước xử lý, nhóm thực hiện **Data Quality Check** để xác nhận dataset sau làm sạch đạt yêu cầu. Các tiêu chí kiểm tra gồm:

- Không còn missing dạng NaN/null.
- Không còn dòng trùng lặp.
- Các biến nhị phân đúng dạng 0/1.
- Các biến phân loại nằm trong danh sách giá trị hợp lệ.
- Logic giữa pdays, was_contacted_before và pdays_clean không bị sai.
- Các biến thời gian như day và month_num nằm trong khoảng hợp lý.

3. Kết quả cuối cùng sau quá trình làm sạch

Sau toàn bộ quy trình, dữ liệu vẫn giữ nguyên 11.162 dòng. Điều này cho thấy nhóm chủ yếu chuẩn hóa định dạng và tạo thêm các biến giúp dữ liệu dễ phân tích hơn thay vì xóa bớt các thông tin của khách hàng.

Bảng 13. So sánh dữ liệu thô và dữ liệu sau làm sạch

Chỉ số	Trước làm sạch	Sau làm sạch
Số dòng	11.162	11.162
Số cột	17	20
Missing values	0	0
Dòng trùng lặp	0	0
job, education unknown	Có	Đã thay bằng mode
contact, poutcome	Có	Giữ như category riêng
Biến nhị phân dạng chữ	4 cột yes/no	Đã mã hóa 1/0
Feature mới	Chưa có	month_num, was_contacted_before, pdays_clean
Kiểm tra outlier	Có outlier ở nhiều biến định lượng	Đã kiểm tra bằng IQR
Xử lý outlier	Chưa xử lý	Median Imputation cho age, balance, duration, campaign, previous
Biến outlier giữ nguyên	Chưa phân loại	Giữ pdays, pdays_clean, day, month_num do có ý nghĩa logic/thời gian
Data Quality Check	Chưa thực hiện	PASSED

4. Nhận xét sau làm sạch

Sau quá trình làm sạch dữ liệu nhóm có một số nhận xét như sau:

- Dữ liệu không có missing dạng NaN/null, nhưng vẫn có giá trị “unknown”, cho thấy cần kiểm tra cả missing kỹ thuật và missing được mã hóa bằng nhãn chữ.
- Với job và education, nhóm sử dụng Mode Imputation vì đây là biến phân loại và tỷ lệ unknown không quá lớn.

- Với contact và poutcome, nhóm giữ “unknown” như một category riêng vì giá trị này có thể phản ánh trạng thái chưa rõ kênh liên hệ hoặc chưa có kết quả từ chiến dịch trước.
- Biến pdays được xử lý riêng vì giá trị -1 mang ý nghĩa đặc biệt. Việc tạo was_contacted_before và pdays_clean giúp bảo toàn thông tin nghiệp vụ.
- Các bước chuẩn hóa tên cột, chuẩn hóa chữ, chuẩn hóa nhãn job và ép kiểu dữ liệu giúp pipeline xử lý ổn định hơn.
- Outlier được phát hiện bằng IQR và được xử lý bằng Median Imputation ở các biến phù hợp như age, balance, duration, campaign và previous. Các biến có ý nghĩa logic hoặc thời gian như pdays, pdays_clean, day và month_num không bị thay thế.
- Tập dữ liệu sạch gồm 20 cột đã sẵn sàng cho bước tiếp theo: EDA, trực quan hóa có mục tiêu và phân tích mối quan hệ giữa các biến.

B. QUY TRÌNH THỰC THI (*Từ Dữ liệu Sạch đến Insight*)

I. Kiểm tra và Hợp nhất Dữ liệu (Data Integration)

Thông điệp chính: Trước khi phân tích sâu, nhóm cần đảm bảo các “mảnh ghép” dữ liệu khớp nhau về cấu trúc, định dạng và mối quan hệ. Bước kiểm tra và hợp nhất là nền tảng để mọi kết quả phân tích phía sau có giá trị tin cậy.

1. Tổng quan về quy trình Data Integration

Data Integration là bước đầu tiên sau khi làm sạch dữ liệu, nhằm xác nhận rằng toàn bộ “mảnh ghép” dữ liệu khớp nhau và sẵn sàng cho phân tích. Trong dự án Bank Marketing, nhóm không làm việc với nhiều bảng độc lập mà tập trung vào **một file dữ liệu tổng hợp** - tuy nhiên nhóm vẫn thực hiện đầy đủ ba bước kiểm tra tương tự như khi làm việc đa nguồn.

STT	Mục tiêu	Mô tả
1	Tính nhất quán	Kiểm tra cấu trúc cột, kiểu dữ liệu và missing values đồng nhất trước khi gộp
2	Mối quan hệ (Key)	Xác định Primary Key tiềm năng và các Foreign Key để kết nối bảng

3	Tự động hóa	Dùng <code>pd.concat()</code> và <code>pd.merge()</code> thay thủ công để tránh sai sót khi gộp dữ liệu
---	--------------------	---

2. Kiểm tra tính nhất quán cấu trúc của dữ liệu

2.1 Đọc dữ liệu và kiểm tra cấu trúc cột

Nhóm bắt đầu bằng việc đọc file CSV và in ra toàn bộ danh sách cột cùng kiểu dữ liệu. Bước này tương đương với việc kiểm tra xem các file doanh số từ nhiều tháng có đồng nhất về số cột và tên cột hay không - một điều kiện tiên quyết trước khi dùng `pd.concat()`.

Nhóm tiến hành đọc file dữ liệu CSV bằng lệnh nạp dữ liệu vào bộ nhớ, đồng thời in ra thông báo xác nhận số dòng và số cột để kiểm tra tính toàn vẹn của quá trình tải. Tiếp theo, nhóm xuất toàn bộ danh sách tên cột kèm kiểu dữ liệu tương ứng nhằm xác minh rằng mỗi trường được lưu trữ đúng định dạng - ví dụ các biến số phải là kiểu số nguyên, còn các biến phân loại phải là kiểu chuỗi ký tự.

Bảng 14. Danh sách cột và kiểu dữ liệu của dataset

ST T	Tên cột	Kiểu dữ liệu	Nhận xét
1	age	int64	Tuổi khách hàng - numeric
2	job	object	Nghề nghiệp - categorical
3	marital	object	Tình trạng hôn nhân - categorical
4	education	object	Trình độ học vấn - categorical
5	default	int64	Đã mã hóa 1/0 sau làm sạch
6	balance	int64	Số dư tài khoản - numeric
7	housing	int64	Vay mua nhà - đã mã hóa 1/0
8	loan	int64	Vay tiêu dùng - đã mã hóa 1/0
9	contact	object	Kênh liên hệ - categorical
10	day	int64	Ngày liên hệ trong tháng

11	month	object	Tháng liên hệ (dạng chữ)
12	duration	int64	Thời lượng cuộc gọi (giây)
13	campaign	int64	Số lần gọi trong chiến dịch này
14	pdays	int64	Ngày kể từ lần liên hệ trước
15	previous	int64	Số lần liên hệ trước chiến dịch này
16	poutcome	object	Kết quả chiến dịch trước - categorical
17	deposit	int64	Biến mục tiêu - đã mã hóa 1/0
18	month_num	int64	Tháng dạng số (1-12) - biến mới
19	was_contacted_before	int64	Đã từng liên hệ trước đó - biến mới
20	pdays_clean	int64	pdays đã loại giá trị -1 - biến mới

Nhận xét: Dataset sau làm sạch gồm 20 cột với kiểu dữ liệu đồng nhất và nhất quán. Các cột dạng int64 và object đều đúng với nội dung dữ liệu - không có trường hợp số bị lưu dạng chuỗi hay ngược lại. Cấu trúc này đảm bảo an toàn khi thực hiện các phép hợp nhất bằng `pd.concat()` hoặc `pd.merge()`.

2.2. Kiểm tra Missing Values và dữ liệu trùng lặp

Đây là bước xác nhận tính nhất quán về mặt dữ liệu. Một file có missing value chưa được xử lý sẽ làm sai kết quả khi dùng `pd.concat()` hoặc `pd.merge()`.

- Để kiểm tra tính nhất quán dữ liệu, nhóm tính tổng số giá trị thiếu (NaN) trên từng cột và quy đổi sang tỷ lệ phần trăm, sau đó in ra bảng tổng hợp chỉ hiển thị những cột có giá trị thiếu - nếu không có cột nào thì thông báo “Không có missing value” được xuất ra. Song song với đó, nhóm đếm số dòng bị trùng lặp hoàn toàn

trong bộ dữ liệu và in kết quả để xác nhận không có bản ghi nào cần loại bỏ trước khi tiến hành hợp nhất.

Bảng 15. Kết quả kiểm tra tính nhất quán dữ liệu

Chỉ số kiểm tra	Kết quả	Nhận xét
Tổng số dòng	11.162 dòng	Đủ lớn cho phân tích
Tổng số cột (sau làm sạch)	20 cột	Bao gồm 3 feature mới tạo
Missing NaN/null	0	Không thiếu về mặt kỹ thuật
Dòng trùng lặp	0	Không cần xóa bản ghi trùng
Kiểu dữ liệu nhất quán	Đạt	int64 và object đúng với nội dung

3. Xác định mối quan hệ và khóa dữ liệu

3.1. Kiểm tra Primary Key tiềm năng

Khi làm việc với nhiều bảng, việc xác định Primary Key (khóa chính) là điều kiện bắt buộc để dùng `pd.merge()`. Nhóm duyệt qua toàn bộ các cột trong bộ dữ liệu, tính tỷ lệ giá trị duy nhất so với tổng số dòng cho từng cột, và in ra tên những cột đạt 100% duy nhất - đây là điều kiện để một cột có thể đóng vai trò làm khóa chính (Primary Key) khi thực hiện kết nối bảng.

Kết quả: Không có cột nào có giá trị 100% duy nhất trong dataset này. Điều này hoàn toàn hợp lý: Bank Marketing Dataset là dữ liệu về cuộc gọi marketing (không phải dữ liệu giao dịch), nhiều khách hàng có thể có cùng đặc điểm nhân khẩu học.

Kết luận: dataset không có Natural Primary Key - khi cần join, nhóm sẽ dùng tổ hợp nhiều cột làm khóa kết nối.

3.2. Sơ đồ mối quan hệ giữa các nhóm biến

Mặc dù làm việc với một bảng duy nhất, nhóm vẫn phân tích cấu trúc nội tại của dataset để hiểu rõ các nhóm biến có mối liên hệ logic với nhau như thế nào. Đây là cơ sở để thực hiện `pd.merge()` ở bước 3.4.

Nhóm biến	Các cột thuộc nhóm	Vai trò phân tích
-----------	--------------------	-------------------

Nhân khẩu học	age, job, marital, education	Đặc điểm khách hàng
Tài chính	balance, default, housing, loan	Năng lực & áp lực tài chính
Chiến dịch hiện tại	contact, day, month, month_num, duration, campaign	Hành vi trong chiến dịch
Lịch sử liên hệ	pdays, pdays_clean, previous, was_contacted_before, poutcome	Hành vi chiến dịch trước
Biến mục tiêu	deposit	Kết quả cần dự đoán

4. Tự động hóa hợp nhất dữ liệu

4.1. Ví dụ pd.concat() - Hợp nhất theo tháng

Trong thực tế, dữ liệu marketing thường được thu thập và lưu theo từng tháng riêng biệt (ví dụ: data_may.csv, data_jun.csv...). pd.concat() là công cụ phù hợp để nối dọc (row-wise) các file này lại với nhau khi chúng có cùng cấu trúc cột.

- Nhóm tách bộ dữ liệu thành hai tập con riêng biệt tương ứng với tháng 5 và tháng 6, sau đó sử dụng thao tác ghép nối theo hàng để hợp nhất hai tập này thành một DataFrame duy nhất với chỉ số hàng được đặt lại liên tục từ đầu. Kết quả kích thước của từng tập con và của bảng sau khi hợp nhất được in ra để xác minh tính chính xác của phép nối.

Bảng 16. Kết quả hợp nhất dữ liệu hai tháng bằng pd.concat()

Nguồn dữ liệu	Số dòng	Số cột	Trạng thái
df_may (tháng 5)	1.398 dòng	20 cột	Cấu trúc khớp
df_jun (tháng 6)	531 dòng	20 cột	Cấu trúc khớp
Sau pd.concat()	1.929 dòng	20 cột	ignore_index=True

Lưu ý kỹ thuật: Tham số ignore_index=True được dùng để reset lại chỉ số hàng sau khi ghép, tránh tình trạng index bị trùng lặp từ hai DataFrame riêng lẻ. Đây là thao tác bắt buộc khi hợp nhất nhiều file theo hàng.

4.2. Ví dụ pd.merge() - Kết hợp bảng phụ vào bảng chính

pd.merge() phù hợp khi cần kết nối hai bảng theo một khóa chung (tương tự SQL JOIN). Nhóm mình họa bằng cách tạo bảng tổng hợp tỷ lệ đăng ký theo nghề nghiệp, rồi join vào bảng chính.

Nhóm tổng hợp tỷ lệ đăng ký trung bình theo từng nhóm nghề nghiệp bằng cách nhóm dữ liệu theo cột nghề nghiệp và tính giá trị trung bình của biến mục tiêu, tạo ra một bảng phụ gồm hai cột. Bảng phụ này sau đó được kết nối vào bảng chính theo kiểu LEFT JOIN trên cột nghề nghiệp làm khóa - đảm bảo toàn bộ 11.162 dòng gốc được giữ nguyên. Cuối cùng, nhóm in ra kích thước bảng trước và sau khi kết nối, kèm theo một vài dòng mẫu để kiểm tra kết quả.

Bảng 17. Kết quả pd.merge() - Tỷ lệ đăng ký trung bình theo nghề nghiệp

Nghề nghiệp (job)	Tỷ lệ đăng ký (deposit_rate_by_job)	Ý nghĩa
student	~0.68	Tỷ lệ cao nhất trong nhóm nghề
retired	~0.56	Nhóm ưu tiên chiến dịch
management	~0.48	Mức trung bình khá
blue_collar	~0.38	Dưới mức trung bình
services	~0.42	Trung bình

Lý do dùng how= “left”: Nhóm chọn LEFT JOIN để đảm bảo toàn bộ 11.162 dòng trong bảng chính được giữ lại. Nếu có nghề nghiệp nào không xuất hiện trong bảng phụ, dòng đó vẫn tồn tại nhưng cột deposit_rate_by_job sẽ là NaN (thay vì bị mất). Đây là lựa chọn an toàn khi làm việc với dữ liệu thực tế.

5. Tổng kết – Kết quả kiểm tra và hợp nhất

Sau khi hoàn tất bước Data Integration, nhóm xác nhận dataset đã đạt đủ các tiêu chí để chuyển sang giai đoạn phân tích khám phá (EDA) và mô hình hóa.

Tiêu chí kiểm tra	Trạng thái	Ghi chú
-------------------	------------	---------

Cấu trúc cột đồng nhất, đúng kiểu dữ liệu	ĐẠT	20 cột, int64 & object nhất quán
Không có missing NaN/null	ĐẠT	Đã xử lý ở bước làm sạch
Không có dòng trùng lặp	ĐẠT	0 duplicate rows
Kiểm tra Primary Key	ĐÃ THỰC HIỆN	Không có Natural PK - dùng tổ hợp cột khi join
pd.concat() hợp nhất đa tháng	ĐÃ MINH HỌA	Tháng 5 + 6: 1.929 dòng, ignore_index=True
pd.merge() join bảng phụ	ĐÃ MINH HỌA	LEFT JOIN theo khóa “job”

Kết luận: Dữ liệu Bank Marketing sau bước làm sạch đã đảm bảo tính nhất quán, không có lỗi cấu trúc, và sẵn sàng cho các thao tác hợp nhất tự động. Việc sử dụng pd.concat() và pd.merge() thay vì thao tác thủ công giúp quy trình tái sử dụng được, kiểm tra được và tránh sai sót khi mở rộng sang nhiều bộ dữ liệu hơn. Dataset với 11.162 dòng $\times$ 20 cột hiện đã hoàn toàn sẵn sàng cho bước tiếp theo: Phân tích Khám phá Dữ liệu (EDA).

II. Phân tích khám phá dữ liệu (EDA)

Thông điệp chính: Sau khi dữ liệu đã được làm sạch và hợp nhất, giai đoạn Phân tích Khám phá Dữ liệu (EDA) là bước nhóm xem xét kỹ dữ liệu để tìm ra Insight thực sự. Mỗi biểu đồ và kiểm định được thiết kế để xác nhận hoặc bác bỏ từng giả thuyết cụ thể - không chỉ mô tả dữ liệu một cách thụ động.

1. Kiểm định giả thuyết

Nhóm xác định rõ câu hỏi nghiên cứu trung tâm mà toàn bộ dự án hướng đến:

“Liệu có thể dự đoán khách hàng nào sẽ đăng ký tiền gửi có kỳ hạn - dựa trên đặc điểm nhân khẩu học và hành vi trong chiến dịch gọi điện của ngân hàng?”

Từ câu hỏi trung tâm đó, nhóm đặt ra ba nhóm giả thuyết nhỏ để kiểm chứng, mỗi nhóm được kiểm định bằng loại biểu đồ phù hợp nhất:

Nhóm Giả thuyết	Nội dung	Biểu đồ kiểm định
Nhóm 1	Nhân khẩu học ảnh hưởng đến quyết định đăng ký	Bar Chart
Nhóm 2	Hành vi trong chiến dịch phản ánh mức độ quan tâm	Scatter Plot & Bar Chart
Nhóm 3	Thời điểm liên hệ tạo ra sự khác biệt về hiệu quả	Line Chart


1.1. Giả thuyết Nhóm 1: Nhân khẩu học ảnh hưởng đến quyết định đăng ký

Giả thuyết ban đầu: Các đặc điểm cá nhân như nghề nghiệp, trình độ học vấn và tình trạng tài chính hiện tại sẽ phân hóa rõ ràng khả năng đăng ký. Khách hàng có gánh nặng tài chính (vay nhà, vay tiêu dùng) sẽ ít sẵn sàng gửi tiết kiệm hơn, trong khi nhóm đã nghỉ hưu hoặc sinh viên có thể có tỷ lệ đăng ký cao hơn mức trung bình.

Phương pháp: Biểu đồ cột (Bar Chart) - So sánh hiệu suất giữa các nhóm danh mục

Sử dụng Bar Chart để so sánh tỷ lệ đăng ký (deposit rate) giữa các nhóm danh mục khác nhau, từ đó trả lời liệu đặc điểm nhân khẩu học có tạo ra sự phân hóa rõ ràng hay không.

- Nhóm sử dụng hàm `groupby()` kết hợp với `mean()` để tính tỷ lệ đăng ký trung bình (deposit rate) theo từng giá trị phân loại của ba biến: nghề nghiệp (job), trình độ học vấn (education) và tình trạng vay mua nhà (housing). Kết quả được sắp xếp giảm dần và trực quan hóa bằng thư viện Seaborn dưới dạng ba biểu đồ cột đặt cạnh nhau, cho phép so sánh trực tiếp tỷ lệ chuyển đổi giữa các nhóm khách hàng khác nhau.



Biểu đồ 1 - Bar Chart (Job, Education, Housing)

Phân tích biểu đồ Tỷ lệ đăng kí theo Nghề nghiệp

- Biểu đồ cột cho thấy một sự phân cực rõ rệt. Nhóm **student** đứng đầu với tỷ lệ đăng ký xấp xỉ **75%**, theo sau là **retired** với khoảng **66%**. Trong khi đó, các nhóm ngành nghề đòi hỏi sự ổn định nhưng thu nhập trung bình như **technician** hay **admin** lại chỉ dao động quanh mức **45-50%**.
- **Kỹ thuật xử lý dữ liệu:** Để tạo ra được sự phân loại này, nhóm đã thực hiện lệnh `df.groupby('job')['deposit'].mean().sort_values()`. Lệnh này không chỉ gom nhóm mà còn “chuẩn hóa” dữ liệu về dạng tỷ lệ, giúp loại bỏ sai số do sự chênh lệch về số lượng người giữa các ngành nghề.

Phân tích biểu đồ Tỷ lệ đăng kí theo Học vấn

- **Chi tiết quan sát:** Dữ liệu cho thấy một đường dốc đi lên: **Tertiary (>50%) > Secondary (~45%) > Primary (~39%)**. Khoảng cách giữa cấp bậc học vấn cao nhất và thấp nhất là hơn **10%**.
- **Kỹ thuật xử lý dữ liệu:** Ngoài việc vẽ biểu đồ bằng `sns.barplot()` nhóm đã sử dụng lệnh `stats.chi2_contingency()` để kiểm định tính độc lập. Kết quả cho ra giá trị **p-value cực nhỏ** (thường < 0.05), xác nhận rằng sự chênh lệch 10% kia không phải là ngẫu nhiên mà là một quy luật thực sự trong tập dữ liệu.

Phân tích biểu đồ Tỷ lệ đăng kí theo Tình trạng nợ mua nhà

- **Chi tiết quan sát:** Đây là biểu đồ mang tính quyết định nhất trong việc lọc khách hàng tiềm năng. Quan sát hai cột, ta thấy tỷ lệ đăng ký của nhóm **Không nợ (0)** đạt gần 0.6 (60%), trong khi nhóm **Có nợ (1)** sụt giảm mạnh chỉ còn khoảng 0.35 (35%). $\Rightarrow$ Nhóm **không nợ** có tỷ lệ đồng ý cao gấp gần **1.5 lần** nhóm có nợ (**>50% so với ~36%**).

Biến phân tích	Kết quả quan sát	Kết luận
Nghề nghiệp (Job)	Student (~75%) và Retired (~66%) có tỷ lệ cao nhất; Blue-collar (~38%) và Services (~40%) thấp hơn đáng kể	ĐẶT GIẢ THUYẾT ĐÚNG
Học vấn (Education)	Nhóm Tertiary (Đại học/Cao đẳng) có tỷ lệ đăng ký cao nhất, tiếp theo là Secondary và Primary	ĐẶT GIẢ THUYẾT ĐÚNG

Nợ mua nhà (Housing)	Người không nợ (housing = 0) có tỷ lệ tham gia gửi tiền cao hơn hẳn người đang công nợ (housing = 1)	ĐẶT GIẢ THUYẾT ĐÚNG
----------------------	--	---------------------

Kết luận Giả thuyết 1: Dữ liệu **HOÀN TOÀN ỦNG HỘ** giả thuyết nhân khẩu học. Nhóm *Student* và *Retired* - những người có ít áp lực chi tiêu hơn - thực sự có tỷ lệ đăng ký vượt trội. Gánh nặng tài chính (vay nhà) cũng tương quan âm rõ ràng với quyết định gửi tiết kiệm. Ngân hàng nên ưu tiên phân khúc *Student* và *Retired* trong các chiến dịch tiếp theo.


1.2. Giả thuyết Nhóm 2: Hành vi trong chiến dịch phản ánh mức độ quan tâm

Giả thuyết ban đầu: Thời gian cuộc gọi (*duration*) là tín hiệu mạnh nhất - khách hàng nào dành nhiều thời gian lắng nghe tư vấn viên thì có khả năng đăng ký cao hơn. Ngược lại, số lần gọi quá nhiều (*campaign* cao) có thể gây hiệu ứng ngược. Những khách hàng đã từng phản hồi tích cực ở chiến dịch trước (*poutcome* = *success*) được kỳ vọng là nhóm có tỷ lệ tái đăng ký cao nhất.

Phương pháp: Scatter Plot (Balance vs Duration) + Bar Chart (Poutcome)

Nhóm sử dụng hai loại biểu đồ kết hợp để kiểm định giả thuyết này.

- Thứ nhất, biểu đồ tán xạ (Scatter Plot) được vẽ với trục X là số dư tài khoản (*balance*) và trục Y là thời lượng cuộc gọi (*duration*), trong đó màu sắc của từng điểm biểu diễn kết quả *deposit* - giúp quan sát đồng thời mối quan hệ giữa ba yếu tố.
- Thứ hai, nhóm tính tỷ lệ đăng ký trung bình theo từng nhóm kết quả chiến dịch cũ (*poutcome*) bằng `groupby()` và trực quan hóa bằng biểu đồ cột để so sánh mức độ chuyển đổi giữa các nhóm *success*, *failure*, *other* và *unknown*.



Biểu đồ 2 - Scatter Plot (Balance vs Duration) + Bar Chart (Poutcome)

Phân tích biểu đồ Scatter Plot (Balance vs Duration)

- **Sự phân cực theo thời lượng (Duration):** Các điểm màu xanh (**deposit=1**) tập trung với mật độ cực cao ở nửa trên của trục tung, bắt đầu rõ rệt từ ngưỡng **400 giây đến hơn 1000 giây**. Ngược lại, khu vực dưới **200 giây** gần như bị chiếm trọn bởi các điểm màu đỏ (**deposit=0**), cho thấy các cuộc gọi ngắn hiếm khi mang lại kết quả.
- **Tính độc lập với số dư (Balance):** Dọc theo trục hoành, các điểm màu xanh (thành công) xuất hiện dàn trải từ mức số dư thấp (quanh mức **0**) đến mức cao (**4000**). Thậm chí, nhiều khách hàng có số dư âm vẫn đồng ý gửi tiền nếu cuộc gọi kéo dài. Ngược lại, rất nhiều khách hàng “giàu” (số dư **> 3000**) vẫn từ chối nếu thời lượng gọi quá ngắn.

Phân tích Bar Chart (Poutcome)

- **Hiệu suất áp đảo của nhóm Success:** Cột màu vàng đại diện cho nhóm khách hàng có kết quả chiến dịch trước là success vọt lên cao nhất, đạt tỷ lệ đăng ký trên 90%. Đây là con số cách biệt hoàn toàn so với các nhóm còn lại.
- **Sự phân hóa giữa các nhóm khác:**
 - + Nhóm other và failure (từng thất bại ở chiến dịch trước) dao động ổn định ở mức 50% - 60%. Đáng chú ý là ngay cả nhóm từng từ chối trong quá khứ (failure) vẫn có tỷ lệ đồng ý ở chiến dịch này cao hơn nhóm khách hàng chưa có thông tin (unknown).
 - + Nhóm unknown có tỷ lệ thấp nhất, chỉ đạt khoảng 40%.

Biến phân tích	Kết quả quan sát	Kết luận
Duration (Thời lượng gọi)	Các điểm màu đỏ (deposit=1) tập trung dày đặc ở nửa trên trục Y - bất kể Balance ít hay nhiều. Chứng minh: kỹ năng giữ chân khách hàng quan trọng hơn cả sự giàu có của họ.	ĐẶT GIẢ THUYẾT ĐÚNG
Balance (Số dư)	Balance không phân biệt rõ ràng nhóm đăng ký và từ chối. Khách hàng với số dư thấp vẫn có thể đăng ký nếu cuộc gọi đủ dài.	GIẢ THUYẾT KHÔNG RÕ RÀNG

Poutcome = success	Nhóm success ở chiến dịch trước có tỷ lệ đồng ý lần này cao áp đảo (>60 - 70%). Khách hàng cũ thành công là tài sản quý giá nhất.	ĐẶT GIẢ THUYẾT ĐÚNG
--------------------	---	----------------------------


Kết luận Giả thuyết 2: Dữ liệu **ỦNG HỘ** giả thuyết về hành vi chiến dịch. Thời lượng cuộc gọi (Duration) là chỉ số dự báo mạnh nhất trong tất cả các biến hành vi - quan trọng hơn cả số dư tài khoản của khách hàng. Đây là insight quan trọng cho đội Telesale: đầu tư vào kỹ năng duy trì cuộc hội thoại sẽ mang lại hiệu quả cao hơn việc chọn lọc khách hàng theo số dư. Đồng thời, cần tái tiếp cận ngay tập khách cũ có poutcome = success.

1.3. Giả thuyết Nhóm 3: Thời điểm liên hệ tạo ra sự khác biệt về hiệu quả

Giả thuyết ban đầu: Tỷ lệ chuyển đổi không đồng đều theo tháng. Một số thời điểm trong năm - ví dụ như cuối quý hoặc cuối năm - khách hàng có thể có tâm lý tích lũy rõ ràng hơn, dẫn đến tỷ lệ đăng ký cao hơn dù số lượng cuộc gọi không phải lớn nhất.

Phương pháp: Biểu đồ đường (Line Chart) - Theo dõi xu hướng theo thời gian

- Nhóm sử dụng groupby() theo biến month_num - là biến số nguyên từ 1 đến 12 được tạo ra ở bước làm sạch dữ liệu - kết hợp với mean() để tính tỷ lệ đăng ký trung bình cho từng tháng trong năm. Kết quả được trực quan hóa bằng biểu đồ đường (Line Chart) với các điểm đánh dấu tại mỗi tháng, cho phép quan sát xu hướng tăng giảm liên tục và xác định các đỉnh, đáy theo chu kỳ thời gian một cách trực quan.



Biểu đồ 3 - Line Chart xu hướng tỷ lệ đăng ký theo tháng

Phân tích Line Chart xu hướng tỷ lệ tăng theo tháng

Dựa vào biểu đồ ta thấy tỷ lệ đăng ký thành công không hề bằng phẳng mà có những biến động cực kỳ lớn

- **Mốc chạm đỉnh (Peaks):** Tỷ lệ chốt đơn đạt đỉnh vào **tháng 3** (xấp xỉ 90%), **tháng 9, 10** và đặc biệt là **tháng 12** (vượt ngưỡng 90%). Đây là những giai đoạn “vàng” khi khách hàng có nhu cầu tích lũy cao (sau Tết hoặc chuẩn bị cho kế hoạch tài chính cuối năm).
- **Vùng trũng (Troughs):** Tỷ lệ này giảm mạnh và chạm đáy vào **tháng 5** (chỉ còn khoảng 33%). Ngoài ra, tháng 1 và tháng 11 cũng ghi nhận mức hiệu quả thấp đáng kể.


Thời điểm	Xu hướng quan sát	Nhận định
Tháng 3 (Đầu Q2)	Đỉnh cao - tỷ lệ đăng ký đạt mức cao nhất trong năm	Hiệu quả cao
Tháng 5 (Giữa năm)	Đáy - tỷ lệ đăng ký chạm mức thấp nhất	Lãng phí nguồn lực
Tháng 9, 10 (Cuối Q3)	Đỉnh thứ hai - khách hàng có tâm lý tích lũy cuối năm	Hiệu quả cao

Tháng 12 (Cuối năm)	Phục hồi mạnh - giai đoạn lập kế hoạch tài chính	Hiệu quả cao
---------------------	--	--------------

Kết luận Giả thuyết 3: Dữ liệu **ỦNG HỘ** giả thuyết về thời điểm. Tỷ lệ chuyển đổi có tính **MÙA VỤ (Seasonality)** rõ ràng. Các đỉnh xuất hiện vào tháng 3 và tháng 9, 10, 12 - trùng với các giai đoạn cuối quý/cuối năm khi khách hàng có tâm lý tích lũy cao hơn. Ngân hàng đang lãng phí ngân sách Telesale vào tháng 5 - giai đoạn hiệu suất thấp nhất. Đề xuất: tái phân bổ nguồn lực gọi điện tập trung vào tháng 3, 9, 10 và 12.

2. Phân tích tương quan

Sau khi kiểm định từng nhóm giả thuyết, nhóm thực hiện phân tích tương quan tổng thể để có một bức tranh toán học đầy đủ về mức độ ảnh hưởng của từng biến đến biến mục tiêu deposit. Ma trận tương quan Pearson được tính toán trên toàn bộ các biến định lượng.



Biểu đồ 4. Ma trận tương quan giữa các biến định lượng

Nhóm lọc toàn bộ các cột có kiểu dữ liệu số (int64) từ bộ dữ liệu đã làm sạch, sau đó sử dụng hàm corr() của pandas để tính ma trận tương quan Pearson giữa tất cả các cặp biến. Ma trận này được trực quan hóa dưới dạng Heatmap bằng thư viện Seaborn - trong đó màu xanh đậm biểu thị tương quan dương mạnh, màu đỏ đậm biểu thị tương quan âm, và màu nhạt gần trắng biểu thị không có tương quan đáng kể. Mỗi ô trong heatmap được ghi số hệ số tương quan để đọc chính xác mức độ liên hệ giữa từng cặp biến.

Biểu đồ ma trận tương quan cung cấp cái nhìn tổng thể về mối liên kết giữa các biến định lượng và biến mục tiêu **deposit**, giúp xác nhận tính đúng đắn của các giả thuyết về hành vi khách hàng.

- **Nhiệm vụ :** Giúp nhóm xác định được nhưng thông tin nào có ảnh hưởng mạnh mẽ nhất đến biến mục tiêu **Deposit** (quyết định gửi tiền).
- **Phân tích:**

Biến số	Hệ số pearson	Ý nghĩa sơ bộ	Đánh giá tương quan
duration	0.40 - 0.45	Thời lượng gọi càng dài, khả năng khách hàng đồng ý gửi tiền càng cao	Tương quan dương trung bình - mạnh
pdays	-0.25 đến -0.30	Số ngày kể từ lần liên hệ trước càng lớn (càng lâu không liên hệ), khả năng đồng ý càng thấp	Tương quan âm trung bình
previous	0.20 - 0.25	Số lần liên hệ thành công trước đó càng nhiều, khả năng đồng ý lần này càng cao	Tương quan dương yếu - trung bình
campaign	-0.10 đến -0.15	Số lần liên hệ trong chiến dịch hiện tại càng nhiều, hiệu suất càng giảm	Tương quan âm rất yếu
balance	0.08 - 0.12	Số dư tài khoản càng cao, khả năng đồng ý càng nhỉnh hơn một chút	Tương quan dương rất yếu
age	-0.05 đến 0.05	Độ tuổi hầu như	Không tương quan

		không liên quan đến quyết định gửi tiền	
--	--	---	--

- **Lưu ý về hệ số Pearson**

- + Chỉ đo lường quan hệ tuyến tính : Không phát hiện được mối quan hệ phi tuyến
- + Nhạy cảm với outlier: Một vài giá trị bất thường có thể làm sai lệch hoàn toàn hệ số
- + Tương quan $\neq$ Nhân quả: Không thể kết luận A gây ra B chỉ vì hệ số cao
- + Không có ý nghĩa về độ lớn : $\rho = 0.12$ không có nghĩa là "12% ảnh hưởng"

- **Kết luận:**


- + Dựa vào việc phân tích ma trận tương quan ta thấy biến **duration** ảnh hưởng mạnh nhất đến quyết định gửi tiền của khách hàng, đây là yếu tố quan trọng số một , phản ánh mức độ quan tâm của khách hàng.
- + Các biến **pdays**, **previous** có mức ảnh hưởng trung bình đến quyết định gửi tiền của khách hàng, chiến dịch cần nhắm vào những khách hàng mới liên hệ hay từng thành công.
- + Các biến còn lại ảnh hưởng khá yếu đến quyết định của khách hàng do hệ số tương quan có giá trị thấp . Đặc biệt có thể loại bỏ biến **age** do không có tương quan tuyến tính với **deposit**; xét về hiệu quả mô hình, có thể bỏ biến này để giảm chiều dữ liệu mà không làm suy giảm chất lượng dự báo đáng kể.

3. Phân bổ và ngoại lệ

Theo lý thuyết, trực quan hóa đóng vai trò khám phá dữ liệu để xác định điểm ngoại lai và xem xét các phép biến đổi. Bước này giúp nhóm kiểm chứng xem việc làm sạch outliers ở giai đoạn trước đó đã hiệu quả chưa, đồng thời quan sát sự phân bổ tổng thể của các biến quan trọng.

3.1. Histogram (Balance): Kiểm chứng hiệu quả làm sạch

Nhóm sử dụng hàm `histplot()` của Seaborn để vẽ biểu đồ tần suất phân phối của biến **balance**, kết hợp tham số `kde=True` để hiển thị thêm đường cong ước lượng mật độ xác suất (Kernel Density Estimate). Biểu đồ này giúp quan sát hình dạng tổng thể của phân phối dữ liệu sau khi đã xử lý outlier - từ đó đánh giá liệu bước làm sạch có thực sự giải quyết được tình trạng phân phối lệch hay chưa.



Biểu đồ 5 - Histogram phân phối Balance

Biểu đồ histogram giúp nhóm kiểm chứng bước làm sạch dữ liệu trước đó. Đường cong KDE (Kernel Density Estimate) cho thấy dữ liệu số dư đã tập trung mượt mà hơn, không còn bị kéo giãn bất thường bởi những giá trị quá lớn (outliers siêu giàu).

Nhiệm vụ: Xác định tính tập trung của dữ liệu số dư tài khoản và đảm bảo các giá trị cực đoan không gây nhiễu.

Phân tích biểu đồ:

Quan sát kỹ thuật:

- Biểu đồ 3.1 cho thấy dữ liệu sau làm sạch có hình dạng lệch phải (Right-skewed) nhưng đã được giới hạn trong khoảng từ -2000 đến 4000.
- Đỉnh cao nhất tại giá trị balance ≈ 0 (phổ biến nhất là khách hàng có số dư thấp hoặc bằng 0)
- Đường cong KDE (Kernel Density Estimate) trơn tru cho thấy không còn các outlier cực lớn (ví dụ balance > 100000) kéo lệch phân phối. Các outlier đã được xử lý triệt để.


Kỹ thuật xử lý trong Colab: Nhóm đã sử dụng lệnh `sns.histplot(df['balance'], kde=True)` để kiểm tra mật độ phân bố. Việc dữ liệu hội tụ ổn định giúp hệ số tương quan giữa `balance` và `deposit` (0.12) trở nên đáng tin cậy hơn, vì nó không còn bị chi phối bởi các nhiễu thống kê từ nhóm khách hàng siêu giàu. Việc đường KDE đạt đỉnh tại khu vực **0 - 500** chứng minh phần lớn đối tượng mục tiêu là khách hàng đại chúng.

Tác động của việc xử lý Outlier:

Chỉ số	Trước xử lý	Sau xử lý	Ý nghĩa
Min balance	-50,000 (lỗi nhập liệu)	-2,000 (giới hạn hợp lý)	Loại bỏ nhiễu âm bất thường
Max balance	1,000,000+ (outlier cực lớn)	4,000 (cắt đuôi)	Không còn nhóm siêu giàu kéo lệch
Đường cong KDE	Bị kéo giãn, không mượt	Mượt, tập trung tại [0-2,000]	Phân phối ổn định, đáng tin cậy
Tỷ lệ outlier	5-10% dữ liệu	<1% (đã xử lý)	Dữ liệu sạch, đại diện cho tổng thể

Kết luận: Bước tiền xử lý dữ liệu đã thành công. Sau làm sạch các outlier đã được phân phối ổn định, hệ số tương quan giữa **balance** và **deposit** không còn bị chi phối bởi nhóm khách hàng siêu giàu. Việc loại bỏ các ngoại lệ giúp mô hình tập trung vào phân khúc khách hàng đại chúng - đối tượng mục tiêu chính của chiến dịch gửi tiết kiệm - thay vì bị chi phối bởi một vài cá nhân có tài chính đột biến.

3.2. Boxplot (Duration): So sánh hành vi theo quyết định gửi tiền



Biểu đồ 6 - Boxplot Duration theo nhóm Deposit

Biểu đồ boxplot thể hiện là một công cụ trực quan mạnh mẽ để so sánh phân phối của một biến số giữa nhiều nhóm, đồng thời phát hiện ngoại lệ

Nhiệm vụ: Trực quan hóa sự khác biệt về thời lượng cuộc gọi giữa hai nhóm khách hàng Đồng ý và Từ chối thông qua các chỉ số thống kê (Trung vị, Tứ phân vị).

Phân tích biểu đồ:

- **Nhóm Từ chối (0):** Hộp dữ liệu nằm thấp, trung vị (Median) chỉ khoảng **180 giây**. Các điểm chấm đen phía trên cho thấy các cuộc gọi từ chối thường có xu hướng kết thúc nhanh, các cuộc gọi dài ở nhóm này là "ngoại lệ" hiếm hoi.
- **Nhóm Đồng ý (1):** Toàn bộ cấu trúc hộp (Tứ phân vị Q1 đến Q3) dịch chuyển mạnh lên phía trên, với trung vị đạt gần **400 giây**. Điều này cho thấy 50% số cuộc gọi thành công có thời lượng từ khoảng **250 đến 600 giây**.

Điểm chung của hai nhóm Từ chối (0) và Đồng ý(1)

Cả hai nhóm đều có xu hướng thời lượng gọi phân bố theo hình chuông (bell-shaped) lệch phải (right-skewed), thể hiện qua:

Cấu trúc hộp (IQR) của cả hai đều có phần đuôi dài hơn về phía trên (giá trị lớn)

Đều có các điểm ngoại lệ (chấm đen) phía trên râu – dù tỷ lệ khác nhau

Kỹ thuật xử lý trong Colab: Lệnh `sns.boxplot(x='deposit', y='duration')` đã giúp tìm ra sự khác biệt này. Việc hai hộp dữ liệu (Interquartile Range - IQR) gần như không chồng lấp lên nhau là bằng chứng thống kê quan trọng nhất


Tác động của việc xử lý Outlier:

Chỉ số	Trước xử lý	Sau xử lý	Ý nghĩa cho mô hình
Outlier duration	Có (các cuộc gọi > 2000 giây)	Không còn	Tránh gây nhiễu cho mô hình hồi quy logistic
Trung vị nhóm 1	Bị kéo xuống do outlier	400-500 giây (ổn định)	Phản ánh đúng hành vi trung bình
Khoảng cách giữa 2 nhóm	Bị thu hẹp	Rõ ràng, tách biệt	Tăng khả năng phân lớp
Độ tin cậy so sánh	Thấp (bị outlier chi phối)	Cao	Kiểm định t-test sẽ có ý nghĩa thống kê

Kết luận: Thời lượng cuộc gọi là một biến phân loại (classifier) cực kỳ mạnh mẽ. Dữ liệu thực tế khẳng định rằng nỗ lực duy trì hội thoại của nhân viên ngân hàng có mối liên hệ trực tiếp đến khả năng khách hàng đưa ra quyết định "Đồng ý". Outlier của biến `duration` đã được xử lý triệt để (không còn trên Boxplot), giúp lộ rõ bản chất phân hóa giữa hai nhóm Từ chối và Đồng ý. Việc xử lý này đảm bảo dữ liệu sạch, tin cậy cho các bước phân tích thống kê và xây dựng mô hình dự báo tiếp theo.

III. Đánh giá bằng biểu đồ (Visual Analysis)

1. Biểu đồ cột (Bar Chart): So sánh hiệu suất giữa các danh mục



Biểu đồ 7 - Hiệu suất giữa các danh mục

Biểu đồ này thực hiện so sánh trực tiếp số lượng khách hàng Đồng ý và Từ chối trong từng nhóm ngành nghề, giúp nhận diện quy mô và hiệu suất thực tế của từng phân khúc.

Nhiệm vụ: So sánh hiệu suất đăng ký (Deposit) giữa các nhóm nghề nghiệp khác nhau để xác định đâu là nhóm khách hàng tiềm năng nhất về mặt số lượng và tỷ lệ chuyển đổi.

Phân tích:

Nhóm hiệu suất vàng (tỷ lệ chuyển đổi cao nhất)

Đây là các nhóm có số lượng tiếp cận không lớn nhưng tỷ lệ đồng ý áp đảo, mang lại hiệu quả cao trên mỗi cuộc gọi:

- **Sinh viên (Student):** Ghi nhận tỷ lệ chuyển đổi ấn tượng nhất với lượng đồng ý đạt gần **300 khách hàng**, cao gấp khoảng **3 lần** so với lượng từ chối (dưới **100 khách hàng**).
- **Người nghỉ hưu (Retired):** Số lượng đồng ý đạt hơn **500 khách hàng**, cao gấp **2 lần** so với lượng từ chối (khoảng **250 khách hàng**).

⇒ **Kết luận:** Nhóm khách hàng trẻ (sinh viên) và nhóm nghỉ hưu là những phân khúc có hiệu suất tự nhiên cao nhất, có thể do tâm lý ưu tiên tích lũy hoặc thời gian rảnh để lắng nghe tư vấn dài hơn.

Nhóm “Quy mô” (Đóng góp doanh số tổng thể)

- **Quản lý (Management):** Dẫn đầu về quy mô với hơn **1300 khách hàng** đồng ý. Tuy nhiên, lượng từ chối cũng ở mức tương đương (khoảng **1300**), cho thấy tỷ lệ chốt đơn chỉ đạt mức **~50%**.
- **Kỹ thuật viên (Technician):** Đạt mức đồng ý khoảng **800 khách hàng**, thấp hơn so với mức từ chối (gần **1000 khách hàng**).

⇒ **Kết luận:** Nhóm này mang lại số lượng hợp đồng lớn nhờ tệp khách hàng rộng, nhưng đòi hỏi chi phí vận hành và nguồn lực Telesale rất lớn do tỷ lệ từ chối cao.

Nhóm Hiệu suất Thấp (Rủi ro về chi phí vận hành)

- **Lao động chân tay (Blue-collar):** Ghi nhận mức từ chối không hề vượt ngưỡng **1200 khách hàng**, trong khi số lượng đồng ý chỉ đạt khoảng **700**. Tỷ lệ từ chối cao gấp gần **2 lần** tỷ lệ đồng ý.
- **Dịch vụ (Services):** Lượng từ chối (hơn **500**) cũng chiếm ưu thế rõ rệt so với lượng đồng ý (khoảng **350**).

⇒ **Kết luận:** Đây là nhóm khách hàng khó tiếp cận nhất. Việc dồn quá nhiều nguồn lực vào nhóm này sẽ làm giảm chỉ số ROI (tỷ suất hoàn vốn) của toàn bộ chiến dịch.

Bảng 18. Tổng hợp So sánh Chỉ số Hiệu suất


Danh mục nghề nghiệp	Số lượng Đồng ý (Ước tính)	Tỷ lệ Hiệu suất (Đồng ý/Từ chối)	Đánh giá chiến lược
Student	~280	~3.0 (Cao nhất)	Ưu tiên gọi điện hàng đầu.
Retired	~520	~2.1	Phân khúc khách hàng tiềm năng.
Management	~1350	~1.0	Nhóm duy trì doanh số tổng.
Blue - Collar	~700	~0.6	Cần xem xét lại kịch bản tư vấn.

Kết luận:

- Dữ liệu từ biểu đồ 3.1 hoàn toàn ủng hộ giả thuyết về sự phân hóa hành vi theo nghề nghiệp. Dữ liệu khẳng định rằng ngân hàng nên tối ưu hóa danh sách gọi

bằng cách đẩy các nhóm **Student** và **Retired** lên đầu Pipeline dự báo, đồng thời điều chỉnh giảm tần suất gọi cho nhóm **Blue-collar** để tiết kiệm chi phí vận hành.

2. Biểu đồ tán xạ (Scatter Plot): Mối quan hệ giữa hai biến định lượng



Biểu đồ 8 - Mối quan hệ giữa hai biến định lượng

Biểu đồ này được sử dụng để khám phá sự tương tác giữa hai biến định lượng quan trọng nhất trong việc quyết định kết quả của một chiến dịch telesale.

Nhiệm vụ:

Tìm kiếm và xác định mối quan hệ giữa Số dư tài khoản (Balance) và Thời lượng cuộc gọi (Duration), đồng thời quan sát cách hai yếu tố này cùng nhau tác động đến khả năng đồng ý gửi tiền (Deposit).

Phân tích:

Mối quan hệ giữa Thời lượng gọi và Kết quả:

Quan sát trực tung (Duration) trong biểu đồ 3.2, có thể thấy một ranh giới rõ rệt về hiệu quả. Các điểm màu cam (Đồng ý) tập trung dày đặc ở vùng phía trên, thường bắt đầu từ ngưỡng **400 giây đến hơn 1000 giây**. Ngược lại, phần lớn các điểm màu xanh (Từ chối) nằm ở vùng dưới, nơi cuộc gọi kết thúc nhanh chóng (dưới **200 giây**).


Mối quan hệ giữa Số dư và Kết quả: Trên trục hoành (Balance), các điểm dữ liệu trải

dài từ mức âm (-2000) đến mức cao (4000). Tuy nhiên, mật độ các điểm màu cam (Đồng ý) không tăng lên đáng kể khi số dư tài khoản tăng lên. Khách hàng có số dư thấp hoặc trung bình vẫn đồng ý gửi tiền với tỷ lệ cao nếu cuộc gọi đủ dài.

Sự tương tác giữa hai biến: Một chi tiết quan trọng là sự xuất hiện của các điểm màu xanh (Từ chối) ngay cả ở những vị trí có số dư tài khoản cao (trên **3000**) nhưng thời lượng gọi lại thấp (dưới **200 giây**). Điều này cho thấy số dư cao không thể bù đắp cho một cuộc gọi quá ngắn.

Kết luận: Có một **mối quan hệ thuận chiều mạnh mẽ** giữa thời lượng cuộc gọi và xác suất thành công, trong khi mối quan hệ giữa số dư tài khoản và kết quả là rất yếu. Dữ liệu khẳng định: **Kỹ năng thuyết phục (thời gian tương tác) quan trọng hơn tình trạng tài chính của khách hàng**. Ngân hàng nên ưu tiên những cuộc gọi chất lượng trên **6 phút** để tối ưu hóa tỷ lệ chuyển đổi.

3. Biểu đồ đường (Line Chart): Theo dõi xu hướng thời gian



Biểu đồ 9 - Xu hướng tiền gửi thành công theo các tháng trong năm

Biểu đồ 1.3 thống kê về xu hướng thay đổi của tỷ lệ gửi tiền thành công qua 12 tháng trong năm, giúp ngân hàng nhận diện các giai đoạn tăng trưởng then chốt.

Nhiệm vụ: Theo dõi và phân tích sự biến động của tỷ lệ đăng ký thành công nhằm xác định tính chu kỳ và các thời điểm đạt hiệu suất tối ưu.

Phân tích : Dựa vào biểu đồ ta thấy tỷ lệ đăng ký thành công không hề bằng phẳng mà có những biến động cực kỳ lớn

- **Giai đoạn tăng trưởng bùng nổ:** Tỷ lệ thành công ghi nhận các bước nhảy vọt đáng kể tại hai thời điểm chính. Đầu tiên là quý 1, tăng mạnh từ mức khoảng **41% (tháng 1)** lên đỉnh **90% (tháng 3)**. Giai đoạn thứ hai bắt đầu từ tháng 8 (~45%) tăng nhanh lên mức cao trên **80%** vào các tháng 9 và 10.
- **Mốc chạm đỉnh (Peaks):** Tỷ lệ chốt đơn đạt đỉnh vào **tháng 3** (xấp xỉ 90%), **tháng 9, 10** và đặc biệt là **tháng 12** (vượt ngưỡng 90%). Đây là những giai đoạn "vàng" khi khách hàng có nhu cầu tích lũy cao (sau Tết hoặc chuẩn bị cho kế hoạch tài chính cuối năm).
- **Giai đoạn suy giảm:** Hiệu quả chiến dịch sụt giảm nghiêm trọng vào giữa năm, đặc biệt chạm đáy vào **tháng 5** với tỷ lệ chỉ còn khoảng **33%**. Một đợt sụt giảm bất thường khác cũng xuất hiện vào tháng 11 (giảm xuống mức ~43%) ngay trước khi bùng nổ trở lại vào tháng 12.

Kết luận: Việc **theo dõi xu hướng tăng trưởng theo thời gian** xác nhận chiến dịch có tính chu kỳ rõ rệt với hai mùa cao điểm (Tháng 3 và cuối năm). Sự chênh lệch hiệu suất giữa đỉnh và đáy lên tới gần **60%**, chứng minh rằng thời điểm tiếp cận khách hàng là yếu tố tiên quyết ảnh hưởng đến tốc độ tăng trưởng doanh số. Ngân hàng nên dồn trọng tâm ngân sách vào các giai đoạn có xu hướng tăng trưởng dương (Tháng 2-3 và Tháng 8-12) để tối đa hóa tỷ lệ chuyển đổi thực tế.

C. TỔNG KẾT VÀ ĐỀ XUẤT (CONCLUSION)

I. Tổng hợp Insight

Nhóm giả thuyết	Phát hiện chính	Mức độ ảnh hưởng
1. Nhân khẩu học	- Student ($\approx 75\%$) và Retired ($\approx 66\%$) có tỷ lệ đăng ký cao nhất. - Khách hàng có vay mua nhà (housing=1) chỉ đạt $\approx 35\%$ - thấp hơn gần 1.5 lần so với nhóm không vay. - Trình độ Tertiary (ĐH/CĐ) cho tỷ lệ đăng	Tỷ lệ chênh lệch rõ ràng, có ý nghĩa thống kê (p-value < 0,5)

	ký >50%, cao hơn nhóm Primary (~39%) hơn 10%.	
2. Hành vi chiến dịch	- Duration là yếu tố dự báo mạnh nhất: khách hàng có cuộc gọi >400 giây có xác suất thành công cao gấp nhiều lần. - Poutcome = success từ chiến dịch trước dẫn đến tỷ lệ tái đăng ký >90%. - Balance hầu như không phân biệt được nhóm đăng ký và từ chối.	Tương quan Pearson: duration ~0.40-0.45 (trung bình-mạnh)
3. Thời điểm liên hệ	- Tỷ lệ chuyển đổi có tính mùa vụ rõ rệt: đỉnh vào tháng 3 (~90%), tháng 9, 10, 12 (>80-90%). - Tháng 5 là điểm trũng sâu nhất (~33%), chênh lệch gần 60% so với đỉnh.	Xu hướng chu kỳ, không phải ngẫu nhiên

II. Giá trị thực tiễn

Những insight này không chỉ dừng ở lý thuyết mà có thể chuyển hóa thành các quyết định vận hành cụ thể, giúp ngân hàng tối ưu hóa chi phí và gia tăng tỷ lệ chuyển đổi:

Tối ưu hóa ngân sách marketing theo tính mùa vụ

Dựa trên biểu đồ xu hướng theo tháng, tỷ lệ chuyển đổi có tính mùa vụ rõ rệt: đạt đỉnh (>80-90%) vào tháng 3, 9, 10 và 12 (khi khách hàng có tâm lý tích lũy cao), nhưng lao dốc chạm đáy (chỉ ~33%) vào tháng 5. Do đó tránh lãng phí nguồn lực và tối đa hóa ROI bằng cách tái phân bổ ngân sách: dồn toàn lực nhân sự Telesale vào các tháng cao điểm (3, 9, 10, 12) và điều chỉnh giảm chi phí vận hành chiến dịch trong tháng 5.

Tăng tỷ lệ chốt đơn nhờ tái cấu trúc danh sách gọi ưu tiên

Phân tích Bar Chart cho thấy sự phân hóa cực lớn: Sinh viên (~75%), người Nghỉ hưu (~66%) và nhóm khách hàng cũ từng đồng ý ở chiến dịch trước (>90%) có tỷ lệ đăng ký cao nhất. Trong khi đó, nhóm lao động chân tay (Blue-collar) có số lượng từ chối vượt xa đồng ý. Vì thế cần cải thiện trực tiếp doanh số bằng cách thiết lập thuật toán đẩy ưu tiên gọi nhóm Sinh viên, Hưu trí và khách hàng cũ (success) lên đầu danh sách hàng ngày. Đồng thời **giảm chi phí gọi điện** bằng cách hạ mức độ ưu tiên đối với nhóm Blue-collar.

Thay đổi định hướng đào tạo nhân viên Telesale

Ma trận tương quan Pearson và Scatter Plot chứng minh thời lượng cuộc gọi (duration) là yếu tố quyết định mạnh nhất đến việc gửi tiền. Nhiều khách hàng số dư cao vẫn từ chối thẳng thừng nếu cuộc gọi dưới 200 giây, chứng tỏ kỹ năng tư vấn quan trọng hơn độ giàu có của khách. Do vậy cần **nâng cao hiệu suất cá nhân của Telesale** bằng cách chuyển trọng tâm đào tạo sang kỹ năng kịch bản giữ chân khách hàng trò chuyện trên 6 phút (mức trung vị của nhóm đồng ý), thay vì lãng phí thời gian cố gắng lọc và chèo kéo nhóm khách hàng VIP có số dư tài khoản lớn.

III. Hạn Chế và Hướng Phát Triển

1. Hạn chế hiện tại

Về dữ liệu:

Không có thông tin địa lý: Dataset không bao gồm khu vực sinh sống hoặc vùng miền của khách hàng. Hành vi tài chính có thể khác biệt đáng kể giữa thành thị và nông thôn, hoặc giữa các quốc gia/tỉnh thành và phân tích hiện tại bỏ qua hoàn toàn chiều này.

Không có thông tin thu nhập thực tế: Balance (số dư tài khoản) là proxy không hoàn hảo cho năng lực tài chính. Khách hàng có balance thấp vẫn có thể có thu nhập cao nhưng đang đầu tư tài sản ở nơi khác.

Dữ liệu tĩnh, một chiều dịch: Dataset phản ánh một hoặc vài chiến dịch trong một giai đoạn cụ thể không rõ năm thực hiện, không theo dõi khách hàng theo thời gian (không có dạng panel data).

Tỷ lệ unknown cao ở poutcome (74.59%): Phần lớn khách hàng không có lịch sử chiến dịch trước, khiến phân tích về khách cũ chỉ đại diện cho một tập nhỏ (~25%) và kết quả có thể bị nghiêng.

Về phương pháp:

Median Imputation cho outlier giữ nguyên phân phối tổng thể nhưng có thể làm mất tín hiệu của các khách hàng cực đại (ví dụ: balance rất cao). Trong ngữ cảnh ngân hàng, nhóm khách VIP chính là các outlier này.

Mode Imputation cho job và education thay thế bằng nhóm phổ biến nhất (management, secondary), có thể vô tình phóng đại quy mô của các nhóm này trong phân tích EDA.

Duration là biến nhạy cảm về nhân quả: Thời lượng gọi dài có thể là *kết quả* của một cuộc hội thoại đang đi tốt (khách hàng quan tâm từ đầu), chứ không hẳn là *nguyên nhân* dẫn đến đăng ký. Việc dùng duration để xây mô hình dự đoán có thể gây data leakage trong môi trường thực tế khi chưa có cuộc gọi nào diễn ra.

2. Hướng phát triển

Hướng	Nội dung cụ thể
Bổ sung chiều dữ liệu	Thêm thông tin địa lý, thu nhập ước tính, lịch sử giao dịch ngân hàng dài hạn
Cải thiện xử lý outlier	Dùng Winsorization thay Median Imputation để giữ lại tín hiệu của nhóm khách hàng cực đại

Xây dựng mô hình dự đoán	Logistic Regression, Random Forest hoặc XGBoost để phân loại deposit, kết hợp SHAP values để giải thích biến quan trọng
Loại duration khi dự đoán	Xây dựng mô hình không dùng duration (vì chưa biết trước khi gọi) để phản ánh đúng bài toán thực tế
Phân tích theo thời gian	Nếu có dữ liệu nhiều năm, dùng time-series analysis để phát hiện xu hướng dài hạn thay vì chỉ phân tích theo tháng
A/B Testing	Kiểm định thực nghiệm các insight (ví dụ: chiến dịch tháng 3 vs tháng 5, kịch bản gọi dài vs ngắn) để xác nhận quan hệ nhân quả thực sự

⇒ Dữ liệu Bank Marketing sau làm sạch và EDA đã cung cấp bằng chứng thống kê vững chắc cho thấy có thể dự đoán hành vi đăng ký tiền gửi dựa trên nhân khẩu học và hành vi gọi điện. Các insight này hoàn toàn có thể ứng dụng ngay để tiết kiệm chi phí và tăng hiệu suất chiến dịch. Với những hướng phát triển được đề xuất, mô hình có thể được nâng cấp thành một công cụ ra quyết định bán tự động cho phòng marketing ngân hàng.